

**Universitatea
Transilvania
din Brașov**

**FACULTATEA DE MATEMATICĂ
ȘI INFORMATICĂ**

Lucrare Disertație

Autor: Hanganu Bogdan

Coordonator: Lect. Univ. Băicoianu Alexandra

Brașov
Iulie 2022



Universitatea
Transilvania
din Brașov

FACULTATEA DE MATEMATICĂ
ȘI INFORMATICĂ

Lucrare Disertație

Detectarea emoțiilor prin canale multiple

Autor: Hanganu Bogdan

Coordonator: Lect. Univ. Băicoianu Alexandra

Brașov
Iulie 2022

Cuprins

1	Abstract	1
2	Introducere	2
3	Recunoașterea emoțiilor	3
4	Noțiuni teoretice	7
4.1	Inteligența artificială	7
4.1.1	Rețele neurale convoluționale	10
4.1.2	Rețele neurale recurente	12
4.1.3	Antrenare utilizând procesorul grafic	14
4.2	Procesare digitală de semnal	15
4.2.1	Transformata Fourier	16
4.2.2	Transformata Fourier pe termen scurt	17
4.3	Procesarea imaginilor	19

1 Abstract

Această lucrare de disertație este elaborată în jurul problematicii identificării emoțiilor unei persoane. Utilizând metode de învățare automată, datele sunt înregistrate prin intermediul unor canale multiple (audio, video și text). Expresiile faciale, obținute prin intermediul canalului video, reflectă în mod intuitiv starea mentală a unei persoane, fiind una dintre cele mai bogate și importante forme de comunicare inter-umană. Tonalitatea vocii care se adresează în timpul comunicării ne poate oferi informații valoroase referitoare la starea de spirit. Mesajul care este transmis prin intermediul vocii, ne oferă informații referitoare la personalitatea individului, fiind de ajutor mai departe în procesul de analiză. Datele stocate sunt mai apoi prelucrate folosind tehnici de procesare specifice fiecărui canal. Pentru input-ul audio este folosită procesarea digitală de semnal, cu următoarele tehnici reprezentative: Transformata Fourier, Transformata Fourier pe termen scurt, Coeficienți Mels. Procesare de imagini pentru canalul video vine în adăugare cu: scalare de date, transformare imaginii în greyscale, iar pentru text este de menționat: tokenizare, lematizare. Fiecare bloc de date preprocesat în mod corespunzător canalului părinte, va trece mai departe prin pasul de recunoaștere cu ajutorul metodelor de învățare automată. În această lucrare au fost realizate o serie de experimente pentru: procesarea datelor, antrenarea modelelor de machine learning. Finalizarea acestor teste a avut ca urmare dezvoltarea aplicației "Multimodal Emotion Detection" care să vină în sprijinul procesului de interviuare.

2 Introducere

Aplicația "Multimodal Emotion Detection" are ca audiență persoanele care doresc să facă o analiză a candidatului care a trecut printr-un proces de interviu. Fiind scrisă în limbajul de programare Python, permite o manevră concisă a datelor înregistrate, care pot fi mai apoi vizualizate de către utilizator prin intermediul framework-ului GUI (Graphical User Interface) QT (pronunțat "cute").

În cadrul lucrării, se propune recunoașterea emoțiilor utilizatorului într-un mod inteligent, utilizând tehnici și metode de Machine Learning și Deep Learning. Aceste două procedee sunt subcategoriile ale domeniului numit inteligență artificială, domeniu care a început să se modeleze în funcție de nevoile oamenilor.

Dezvoltarea rapidă a inteligenței artificiale, "Big data science" și a tehnologiei "Block chain" a provocat multiple schimbări în structura socială umană. În majoritatea proceselor unde este nevoie de interacțiune umană, se implementează automatizări care să sporească eficiența, să folosească resursele umane, software și hardware în mod cât mai eficace. La nivel industrial, sistemele automatizate inteligente sunt deja folosite în uzine, fabrici, având rolul de a asigura în permanență buna funcționare a întregului ansamblu. Atât eficiența cât și performanțele acestor sisteme sunt motivate de către costul redus de mentenanță. La un nivel mai aproape de către utilizatori, putem realiza că inteligența artificială a început tot mai des să facă parte din viața de zi cu zi, ajungând în stadiul să devină indispensabil oamenilor.

În zilele noastre, interacțiunea dintre oameni și I.A. este în continuă creștere, ajungând să intre treptat în viața noastră de zi cu zi. De la asistenți virtuali (care au rolul de a sprijini utilizatorul prin intermediul interpretării comenzilor vocale), până la reclame personalizate, aceste sisteme inteligente interacționează din ce în ce mai mult cu ființe umane. Deoarece este un subiect în care interesul este unul foarte crescut, relația între om și mașină inteligentă poate să ajungă la un nivel mai înalt, prin integrarea cu emoțiile utilizatorului. Acesta este un domeniu crucial de cercetare, oferind diverse oportunități și aplicații pentru oameni.

Astfel, în următorul capitol va fi explicat despre fiecare din cele trei tipuri de recunoaștere a emoției utilizate, precum și modul în care acestea interacționează cu utilizatorul. Vor fi prezentate exemple de alte categorii de recunoașterii de emoții, care nu au fost încadrate în această lucrare, precum și aplicațiile care sunt deja în domeniul comercial și sunt utilizate.

3 Recunoașterea emoțiilor

Un aspect cheie în această sferă care să sporească parteneriatul între om și mașină este dat de înțelegerea emoțiilor umane. Emoția este un factor important atât în comunicarea verbală, cât și în comunicarea nonverbală (gesticulare, expresiile corpului). Identificarea stărilor unei persoane poate ajuta o mașină să înțeleagă intențiile utilizatorului, în scopul de a-i oferi o interacțiune mai potrivită. Printre primele studii care au fost făcute pentru integrarea sistemelor inteligente cu emoțiile umane, acestea s-au reflectat în identificarea emoțiilor prin voce, deoarece comunicarea verbală este una dintre cele mai rapide forme de socializare, cu cel mai mare impact în istorie.

Fiind una dintre cele mai consacrate aptitudini prin care o ființă inteligentă s-a putut diferenția și avansa în lanțul trofic, comunicarea verbală reprezintă un semnal complex, în care sunt transmise informații referitoare la mesaj, legate de emițător precum și de emoțiile transmise de acesta. Fiind o serie complexă, capacitatea sistemului care face identificarea emoțiilor trebuie să fie pe măsură, pentru a analiza cu acuratețe starea subiectului, oferindu-i astfel o experiență cât se poate de autentică. Nu numai atât, utilizând o astfel de recunoaștere, poate ajuta la crearea unor interfețe ușor navigabile ("Recunoașterea emoțiilor prin vorbire este deosebit de utilă pentru aplicațiile din domeniul interacțiunii om-mașină deoarece ajută la crearea unor interfețe ușor de utilizat"[1]).

Deoarece semnalul audio conține și alte informații precum emoția transmisă de către emițător, algoritmul de recunoaștere a emoțiilor umane prin extragerea trăsăturilor acustice capturate în vorbire, devine "baza pentru realizarea unei interacțiuni om-calculator mai armonioasă și mai eficientă, având o mare importanță în cercetare, precum și aplicativă"[2].

În cadrul aplicației, vocea utilizatorului (semnalul audio) este folosită în două contexte. Primul este dat de către identificarea emoțiilor candidatului pe baza a diferite trăsături acustice depistate din voce iar al doilea de către identificarea cuvintelor rostite, pentru a putea fi transformate în text. Deoarece în aplicație identificarea textului (speech-to-text) este utilizat prin intermediul unor apeluri de tip API Rest la funcționalitățile oferite de către Google, accentul se va pune pe prima utilizare în lucrare. Emoțiile care pot fi identificate în cadrul acestei recunoașteri sunt următoarele: furie, dezgustare, frică, fericire, tristețe, surprindere, neutral.

Seviciului oferit de către Google pentru recunoașterea textului [3] este folosit cu scopul de a facilita identificarea personalității și a emoției transmise în urma interviului de către utilizator. Recunoașterea emoțiilor din text este în mod fundamental o problemă de clasificare pe baza conținutului, care include noțiuni de procesare de text (NLP, acronim de la "natural language processing"), precum și din domeniul deep learning. Modelul utilizat pentru acest tip de predicție este "The Big Five personality traits"[4].



Figura 1: Cele cinci mari trăsături de personalitate
<https://blog.adioma.com/5-personality-traits-infographic/>

În zilele noastre, se consideră că există 5 categorii de personalități (Figura 1), având acronimul OCEAN. Mai jos, vom prezenta aceste personalități de bază:

- **Openness (Deschidere):** această trăsătură prezintă caracteristici precum imaginația și perspicacitatea. Oamenii care au punctat mai mult în această trăsătură tind să aibă o arie mai mare de interese. Sunt curioși de fire, dornici să dobândească aptitudini noi și să se bucure de orice experiență acumulată.
- **Conscientiousness (Conștiinciozitate):** printre caracteristicile de baza ale acestei trăsături, putem include un nivel ridicat de atenție, control bun al impulsurilor și comportamente care conduc spre îndeplinirea obiectivelor. Oamenii care se încadrează acestei categorii tind să fie mai organizați și atenți la detalii. Ei planifică din timp, se gândesc la modul în care comportamentul lor îi afectează pe alții și sunt atenți la termenele limită.
- **Extraversion (Extraversie):** se caracterizează prin excitabilitate, sociabilitate și cantități mari de expresivitate emoțională. Oamenii care au un nivel ridicat

de extraversie tind să capete energie în situații sociale. A fi în preajma altor persoane îi ajută să se simtă plini de energie și entuziasm. Oamenii care au un nivel scăzut de extraversie (sau introvertiți) tind să fie mai rezervați și au mai puțină energie în mediile sociale. În urma evenimentelor sociale se pot simți extenuați, iar introvertiții necesită adesea o perioadă de singurătate și tăcere pentru a își putea "reîncărca bateriile".

- Agreeableness (Agreeabilitate): pentru această personalitate, sunt incluse atribute precum încrederea, altruismul, bunătatea, afecțiunea și alte comportamente pro-sociale. Oamenii cu grad ridicat de agreeabilitate tind să fie mai cooperativi, în timp ce aceia care au punctat mai slab pentru acest atribut, tind să fie competitivi și uneori chiar manipulativi.
- Neuroticism (Nevrotism): este un atribut caracterizat prin tristețe, melancolie și incoerență emoțională. Persoanele care au această trăsătură au tendința de a experimenta schimbări de dispoziție, anxietate, iritabilitate și tristețe. Aceia care au punctat scăzut în acest caz, tind să fie mai stabili și rezistenți emoțional.

Nu în cele din urmă, după procesul de recunoaștere a trăsăturilor și emoțiilor transmise din voce, mai apoi interpretate în mod contextual prin procesare de text, urmează recunoașterea emoțiilor din cadrul expresiilor faciale. Pentru a putea fi în stare să facem o astfel de analiză, este nevoie identificarea unui chip uman (în engleză "face detection"). Pentru a facilita acest proces, prin intermediul camerei web care ne oferă flux de date video, biblioteca OpenCv[5] ne oferă suport pentru mijloace de identificare a fețelor candidaților. Având acest rezultat intermediar, este posibilă recunoașterea emoțiilor pe baza expresiilor faciale. Principalele stări emoțive din cadrul fluxului video sunt aceleași ca cele din audio.

Făcând un ansamblu al componentelor descrise mai sus, acestea se unifică în ceea ce vom numi "Modulul de interviu". În cadrul acestui modul, predicțiile pentru componentele audio și video sunt făcute live, iar în cazul textului, este realizat la final pentru a avea o cantitate mai ridicată de date, obținând astfel o predicție cât mai aproape de adevăr.

Tipurile de identificare a emoțiilor utilizate și descrise mai sus sunt doar câteva modele existente prin care o aplicație/mașină inteligentă poate interacționa în mod personalizat cu utilizatorul. Printre alte tipuri care merită menționate se enumeră gesturile corpului (limbajul corpului), fiind un subiect mai puțin explorat. Chiar dacă este un aspect important al psihologiei umane, primule studii moderne au devenit populare debia în 1960. Probabil cea mai importantă lucrare publicată înainte de secolul al XX-lea a fost "Expresia emoțiilor la om și la animale", scrisă de Charles Darwin [6].

În acest domeniu, după o cercetare a pieței care construiesc software-uri în jurul predicției emoțiilor, putem considera aplicațiile menționate mai jos ca fiind similare

cu cea prezentată în această lucrare:

- Noldus Solutions Emotion Analysis cu "FaceReader™" [7]: este un software specializat pe analizarea datelor de tip imagine (atât din video cât și statice). Este un sistem robust, capabil să recunoască un număr de proprietăți specifice în imaginile faciale, inclusiv cele șase expresii de bază sau universale: fericit, trist, furios, surprins, speriat și dezgustat.
- iMotions cu "Facial Expression Analysis" [8]: este un software specializat atât în analiza imaginilor cât și a datelor biosenzoristice. Modulul oferă 20 de măsuri de expresie facială (unități de acțiune), 7 emoții de bază, repere faciale, indici comportamentali, cum ar fi orientarea capului și atenția.

Diferența pe care o aduce aplicația prezentată în lucrare ("Multimodal Emotion Detection") este reprezentată de capacitate recunoașterii în timp real a emoțiilor prin intermediul altor input-uri, precum și a feedback-ului constant. Un alt aspect important prin care se diferențiază aplicația în cauză este dat de "Modulul de vizualizare a raportului", prin care se poate vedea la fiecare segment de date, textul care a fost spus, emoțiile prezise din input-ul audio, video, cât și o spectogramă pentru intervalul selectat de date în care s-a efectuat predicția.

Gama de public cărui este adresată această aplicație este reprezentată în general de persoanele care trec prin procesul de interviu. Dar asta nu înseamnă că recunoaștere emoțiilor se limitează la această aplicativitate. Mai jos sunt listate o serie de utilizări:

- Marketing personalizat: un studiu realizat de OneSpot Research a arătat că în proporție de 88% dintre consumatorii chestionați au declarat că un conținut mai personalizat îi face să se simtă mai bine cu privire la un anumit brand.
- Diagnostic medical: o aplicativitate în care poate sprijini medicii cu diagnosticarea afecțiunilor nevrotice precum depresia sau demența, utilizând analiza vocală
- Educație: diferite software-uri didactice în variantă prototip au fost elaborate pentru a se acomoda la emoția copiilor. Când copilul exprimă frustrare pentru că o sarcină este prea simplă sau dificilă, programul se adaptează astfel încât sarcina să se schimbe într-o formă mai adecvată.

În următoarele capitole, vom trece printr-o inițiere în inteligența artificială, procesare digitală de semnal, procesare de imagini și text. Având aceste cunoștințe asimilate, următoarele subiecte propuse care vor fi comentate se vor afla în sfera tehnologiilor utilizate, fără de care nu s-ar fi putut crea aceste teste, precum și aplicația "Multimodal Emotion Detection".

4 Noțiuni teoretice

4.1 Inteligența artificială

David Fogel a definit inteligența ca fiind "abilitatea unui sistem de a se adapta astfel încât să își poată îndeplini scopurile cu succes". Astfel, o mașinărie programată și dotată cu inteligență artificială este un sistem complex capabil să facă decizii, fără nevoia intervenției unei persoane, simulând inteligența umană. Perturbarea funcționării unui astfel de sistem poate altera fluxul evenimentelor în luarea deciziilor, ajungând astfel la rezultate nejustificabile. Principalele subcategorii ale I.A. sunt: machine learning (învățare automată) și deep learning (învățare profundă).

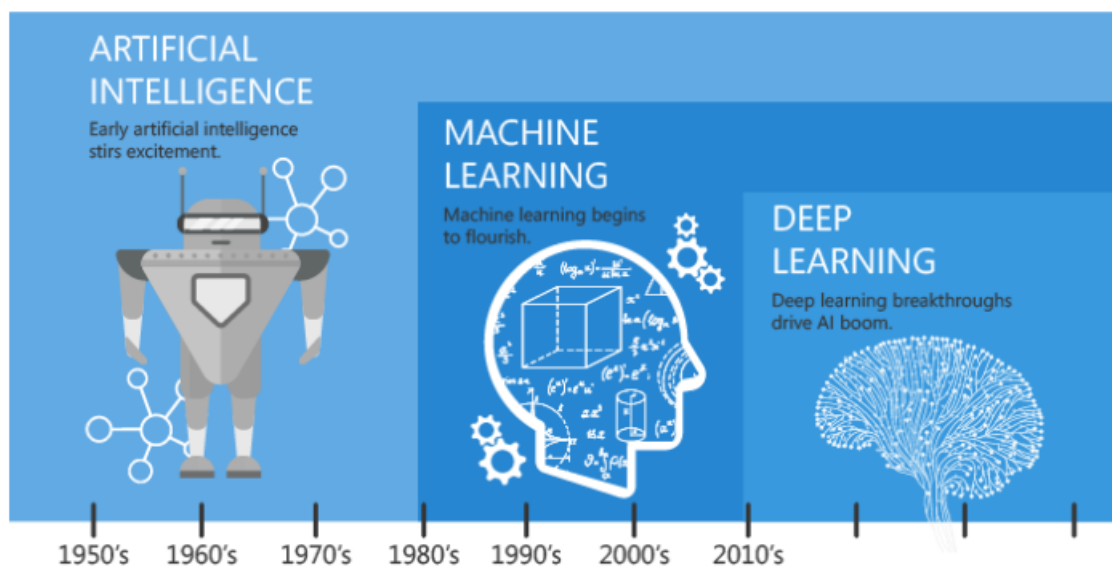


Figura 2: Dezvoltarea inteligenței artificiale

<https://towardsdatascience.com/artificial-intelligence-vs-machine-learning-vs-deep-learning-2210ba8cc4ac/>

Așa cum se observă în Figura 2, putem afirma că inteligența artificială este un termen mai vast care cuprinde celelalte două subcategorii. Aplicațiile care utilizează acest tip de tehnologie imită funcțiile cognitive pe care oamenii le asociază cu mințile umane, cum ar fi învățarea sau rezolvarea anumitor probleme.

Învățarea automată (machine learning) înglobează algoritmi clasici pentru diferite tipuri de sarcini, precum regresia sau clasificarea. Acești algoritmi sunt dependenți în permanență de datele utilizate în procesul antrenării. Cu cât sunt mai multe date și cu cât aceste date sunt mai relevante pentru problema care încearcă să se soluționeze, randamentul acestora va crește. Antrenarea lor reprezintă cel mai important pas, deoarece în acest proces, se presupune minimizarea funcției de eroare (loss function). Rolul acesteia este de a stabili valorile de adevăr între ce a fost prezis, și ade-

vărata clasă a datelor respective. În raport cu răspunsul funcției de eroare în cauză, anumite valori denumite greutate (weights) vor fi actualizate.

În învățarea automată există două categorii de date din care se poate învăța: date etichetate și date neetichetate. În prima categorie, atât parametrii de intrare cât și cei de ieșire sunt într-o formă ușor de citit pentru mașină, fiind nevoie de o cantitate mare de timp pentru a putea eticheta. În cazul datelor neetichetate, este nevoie de o soluție mai complexă pentru a putea utiliza acele informații. Astfel, reies la suprafață trei tipuri de învățare în machine learning:

- **Învățare supervizată:** este una din cele mai de bază tipuri de învățare automată. Chiar dacă este antrenat cu date etichetate, acest gen de învățare este unul foarte puternic. Se folosește un set de date (sau o parte din acest set de date, în general referindu-ne ca set de antrenare), care servește algoritmului cu scop de pregătire, iar alt set de date pentru a testa performanțele modelului.
- **Învățare nesupervizată:** principalul avantaj al acestei categorii este capacitatea algoritmilor de a lucra cu seturi de date neetichetate, eficientizând timpul programatorului. Permit astfel algoritmilor să exploreze și să găsească diferite șabloane și asocieri în seturile de date.
- **Învățare prin "întărire" (reinforcement):** se inspiră direct din modelul în care ființele umane învață din experiențele din viața de zi cu zi. Dispune de un algoritm care se îmbunătățește pe sine și învață din situații noi folosind o metodă de "încearcă și greșește" (în engleză trial and error). Rezultatele favorabile sunt încurajate sau "întărite", iar rezultatele greșite sunt descurajate sau "pedepsite".

Referitor la Figura 2, se poate constata că machine learning este un domeniu destul de îmbătrânit, care încorporează metode și algoritmi, precum: Naive Bayes Classifier, Support Vector Machine, Random Forest.

Recent, în industria inteligenței artificiale, a apărut conceptul de deep learning, care assemblează rețele artificiale neurale cu mai multe straturi. Deep learning poate fi definit ca un subset al învățării automate, care încearcă rezolvarea problemelor mai complexe prin găsirea unor diferite șabloane (pattern-uri) în date, acestea pentru oameni fiind insesizabile cu ochiul liber.

Avantajul pe care îl aduc aceste tipuri de rețele față de cele tradiționale, este dat de eliminarea necesității de a extrage caracteristici (feature) din cadrul setului de date. Rezultatul extragerii caracteristicilor din setul de date definește o reprezentare abstractă a datelor. Acest proces este de obicei destul de complicat, care necesită cunoștințe detaliate în aria specifică a problemei care se încearcă soluționarea. Pasul extragerii trebuie revizuit de multiple ori, testat și rafinat pentru a obține rezultate optime.




Figura 3: Analogie învățare automată și învățare profundă
https://www.researchgate.net/figure/Comparison-between-ML-and-DL-algorithm_fig5_344628869/

Pe de altă parte, în Figura 3, se poate observa cum în cazul învățării profunde, pasul de extragere a caracteristicilor nu mai este necesar să fie executat de către programator, ci devine parte în procesul de antrenare a rețelei artificiale. Datele sunt brute și abstractizate astfel încât să poată fi memorate de diversele straturi ale algoritmului inteligent. Această reprezentare comprimată a datelor de intrare este utilizată pentru a construi rezultatul.

Cu ajutorul rețelelor neurale profunde, acestea au făcut posibilă înțelegerea a seturilor de date complexe, precum semnalul audio reprezentând vocea umană, expresiile faciale și textul asociat cu fraze. Datele de antrenare folosite (care vor fi prezentate în capitolele următoare), sunt etichetate, făcând astfel posibilă identificarea emoțiilor și a personalității candidatului. În secțiunea următoare, vom prezenta în mod minimalist modelele utilizate în aplicație:

- Rețele neurale convoluționale
- Rețele neurale recurente

4.1.1 Rețele neurale convoluționale

O rețea neurală convoluțională este un de algoritm inteligent care face parte din clasa modelelor deep learning. În general folosite în vederea artificială (computer vision), CNN (convolutional neural network) primește ca date de intrare, în majoritatea cazurilor, imagini (sau date care au fost structurate sub forma imaginilor), iar în urmă diferitelor operațiuni, se vor găsi pattern-uri în datele de antrenare, nevizibile unei persoane în mod natural. Sunt distinse printre alte tipuri de modele datorită performanțelor ridicate cu date care provin din: imagini, vorbit sau semnal audio.

Din punct de vedere structural, o rețea neurală convoluțională este alcătuită din următoarele componente:

- **Date de intrare:** cum este menționat mai sus, input-ul poate să provină din mai multe categorii, având și canale diferite de culori. Nu există o limită privind dimensiunea datelor, deoarece, scopul întregului proces este de a reduce dimensionalitatea, păstrând datele într-o formă compresată, fără pierderi de informații.
- **Strat(uri) de convoluție:** este elementul de bază al unei astfel de rețele, fiind locul în care majoritatea calculelor au loc. În funcție de dimensionalitatea datelor (matrici 2d sau 3d), va avea loc operația de convoluție, cu ajutorul unor măști (kernel). În urma acestui proces, se vor extrage anumite trăsături importante din cadrul datelor de intrare, care vor ajuta în determinarea apartenenței la o anumită clasă. De exemplu, printr-o speculație, putem considera din Figura 4, în urma unui proces de convoluție, că se poate determina dacă piciorul mamiferului este sau nu al unei zebre. În urmă acestui proces, în funcție de numărul filtrelor, pasul (stride) și padding, se obțin hărți ale caracteristicilor (feature maps).
- **Strat(uri) de pooling:** au rolul de a reduce substanțial dimensiunea spațială, scăzând cantitatea de parametri utilizați pentru calcule în rețea. Totodată, poate controla și "supra-adaptarea" (overfitting) rețelei. Printre tipurile de straturi de pooling, putem menționa următoarele:
 - **Max pooling:** fiind cea mai comună abordare, deoarece oferă cele mai bune rezultate, max pooling va selecta elementul maxim din harta caracteristicilor (porțiunea filtrată de către mască)
 - **Average pooling:** cum reiese și din nume, va selecta valoare medie din porțiunea filtrată de mască
- **Strat(uri) de conectare:** sunt folosite cu scopul conectării neuronilor către stratul de ieșire, unde în funcție de valorile ponderilor fiecărui neuron în parte, se va putea face calculul posibilității apartenenței la o anumită clasă

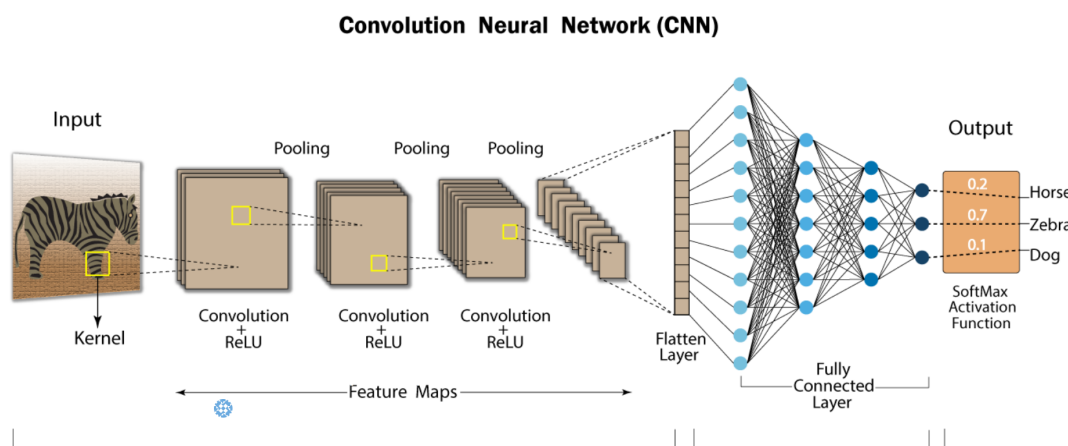


Figura 4: Rețea neurală convoluțională
<https://developersbreach.com/convolution-neural-network-deep-learning/>

Împreună cu informațiile pe care le-am dobândit în urmă prezentării legate de rețelele neurale convoluționale, putem comenta asupra Figurii 4. Din datele folosite pentru antrenare, filtrele aplicate succesiv ne vor ajuta să găsim caracteristici. Transmise mai departe către stratul conectat, se va putea face interpretarea rezultatului, în funcție de gradul de apartenență la fiecare clasă în parte. Rezultatul va fi exprimat în procentaj, iar output-ul cu procentajul cel mai ridicat va exprima clasa decisă.

4.1.2 Rețele neurale recurente

Rețelele neurale recurente sunt un tip robust de rețea neurală, folosite pentru procesarea datelor secvențiale, ordinea lor având importanță. Derivate din rețelele cu propagare înainte (feedforward), RNN-urile (recurrent neural network) prezintă un comportament asemănător cu cel al creierului uman.

La fel ca ceilalți algoritmi de deep learning, rețelele neurale recurente sunt relativ vechi, fiind concepute în 1980, dar doar în ultimii ani a fost descoperit cu adevărat potențialul acestora. Creșterea în puterea computațională, accesul la cantități masive de date pe care le putem utiliza și apariția straturilor cu memorie lungă pe durată scurtă (long short-term memory), au adus RNN-urile în prim plan.

După cum menționează Lex Fridman ("Ori de câte ori există o secvență de date temporale, unde conținutul spațial este mai important decât cel al fiecărui cadru individual"), rețelele neurale recurente au oferit suport pe parcursul lucrării pentru predicția datelor cu strânsă legătură temporală. Aceste rețele și-au îndeplinit scopul în aplicația "Multimodel Emotion Recognition" deoarece atât datele audio cât și cele video depind de ordinea lor în timp.

Datele secvențiale sunt doar date ordonate în funcție de un anumit criteriu. Spre exemplu, putem menționa că datele secvențiale, datele financiare sau chiar secvența de ADN. Cele mai populare date secvențiale sunt reprezentate de către seria temporală, în care sunt enumerate în ordine cronologică. Datele provenite din vorbit, care sunt utilizate în aplicație pentru a prezice emoția, sunt adecvate acestei rețele datorită sortării cronologice standard.

Pentru a înțelege arhitectura acestor rețele, trebuia mai întâi să avem cunoștințe referitoare la mecanismul utilizat de această rețea, propagarea înainte. Într-o rețea neurală feed-forward, informațiile se mișcă doar într-o singură direcție: de la stratul de intrare, prin straturile ascunse, până la nivelul de ieșire. Informația se deplasează direct prin rețea și nu atinge același neuron de două ori. Rețelele simple nu au niciun mecanism de memorare, cu privire la intrarea pe care o primesc, fiind slabe în a prezice ce urmează. Într-un RNN, informația circulă sub formă unei bucle. Când se ia o decizie, se va evalua input-ul curent cât și ce a învățat din experiențele anterioare.




Figura 5: Propagare recurentă și înainte
<https://builtin.com/data-science/recurrent-neural-networks-and-lstm/>

În Figura 5, este ilustrată diferența dintre fluxul de intrare într-o rețea neurală recurentă și o rețea cu propagare înainte.

O rețea neurală feed-forward atribuie, ca toți ceilalți algoritmi de deep learning, o matrice de ponderi care va fi aplicată asupra datelor de intrare, urmând mai apoi să producă rezultatul. Totodată, va avea loc procesul de propagare înapoi (back propagation) pentru actualizarea ponderilor.

Propagarea înapoi este utilizată pentru a calcula gradientul unei funcții de eroare în raport cu ponderile unei rețele neurale. Algoritmul își parcurge calea înapoi prin straturile rețelei, calculând derivatele parțiale ale ponderilor. Această tehnică este folosită pentru a reduce marjele de eroare în timpul antrenamentului.

Mai jos sunt listate diferențele dintre o rețea normală și una recurentă, în contextul celor două propagări:

- Propagarea înainte: în acest pas, RNN-ul va înainta prin aplicarea ponderilor și pentru datele anterior procesate
- Propagarea înapoi: o astfel de rețea modifică greutatea atât prin gradient descent cât și prin propagarea inversă în timp (back propagation through time)

Principalele neajunsuri în cazul acestor algoritmi au apărut datorită gradientului. Primul este denumit "Explozia gradientului" (Exploading Gradient) și apare în cazurile când se asignează valori semnificativ de mari pentru ponderi. Această este ușor rezolvabilă prin trunchierea/plafonarea acestuia. A doua problemă o reprezintă "Gradientul care dispare" (Vanishing Gradient), care apare atunci când valorile gradientilor sunt prea mici, iar modelul încetează să învețe ori o face într-un timp prea mare. Pentru a rezolva această problemă, au fost introduse straturile LSTM (Long Short-Term Memory).

LSTM sunt o extensie pentru RNN-uri, unde se prelungește durata memoriei interne. Sunt folosite ca elemente de bază pentru straturile rețelelor recurente. LSTM-urile asociază încă un set diferit de ponderi folosit pentru a oferi un grad de importanță asupra datelor noi. În funcție de aceste ponderi, datele noi vor putea impacta sau nu pe cele deja existente.

Aceste straturi oferă suport rețelelor recurente să-și "amintească" input-urile pentru o perioadă mai lungă de timp. Funcționalitate lor este asemănătoare cu cea a unui calculator, având capacități de citire, scriere sau ștergere. Această memorie poate fi privită precum o celulă cu porți, care decide dacă să stocheze informația, să o șteargă, în funcție de importanța pe care trebuie să o acorde.

Antrenarea utilizând astfel de rețele poate deveni una costisitoare datorită cantităților mari de date și a complexității calculelor. Procesorul central devine depășit de această ușoare, iar timpul necesar antrenării pentru acești algoritmi poate crește. Soluționarea în acest caz vine prin utilizarea procesorului grafic, acolo unde plăcă video permite acest lucru.

4.1.3 Antrenare utilizând procesorul grafic

Procesorul grafic (graphical processing unit), dezvoltate initial pentru accelerarea procesarii grafice, pot imbunatati performanetele calculelor realizate intr-o retea neurala cu mai multe straturi. Au devenit in o parte esentiala a infrastructurii inteligentei artificiale, iar procesoarele grafice noi au devenit specializate in acest domeniu.

Principalul beneficiu al utilizarii procesorului grafic este dat de paralelizarea sau procesarea simultana a datelor. Exista patru tipuri de arhitecturi folosite pentru procesarea datelor in mod paralel :

- Instructiune unica, date unice
- Instructiune unica, date multiple
- Instructiuni multiple, date unice
- Instructiuni multiple, date multiple

Scopul initial al procesoarelor grafice erau pentru procesarea video, astfel solicitand utilizatorii sa inteleaga limbaje specifice precum OpenGL. In 2007, odata cu lansarea framework-ului (cadru de lucru) NVIDIA CUDA [9], aria utilizarii procesoarelor grafice a fost extinsa. CUDA se bazeaza pe limbajul de programare C si ofera un API pe care dezvoltatorii il pot folosi pentru a aplica puterea de calculatie oferita de placa video in sarcinile de machine learning.

Odata ce NVIDIA a introdus CUDA, au fost dezvoltate mai multe framework-uri pentru invatarea profunda, precum PyTorch si TensorFlow. Aceste tehnologii se folosesc de capabilitatile oferite de CUDA, oferind o accesibilitate mai mare pentru implementarile moderne de deep learning.

Procesoarele grafice pot efectua calcula simultan. Acest lucru permite distribuirea proceselor de instruire si poate accelera semnificati operatiile de invatare automata. Folosind numarul mare de nuclee, putem utiliza mai putine resurse fara a sacrifica eficienta sau putere.

Cand se defineste o arhitectura pentru retelele deep learning, urmatorii factori pot influenta decizia de a utiliza sau nu un procesor grafic:

- Latimea bandei de memorie: datorita memoriei video dedicate (VRAM), GPU-urile pot oferi latimea de banda necesara pentru a acomoda seturi de date
- Dimensiunea setului de date: procesoarele grafice legate in paralel scaleaza mult mai rapid decat procesoarele centrale, permitand procesarea a unor seturi de date masiv din punct de vedere cantitativ

Datorita puterii de procesare a placilor grafice, modelele de deep learning folosite in aplicatie au fost antrenate cu ajutorul procesorului grafic. Placa video utilizata in cauza este un GeForce RTX 2060 (editia laptop), oferind 1920 procesoare CUDA si 240 procesoare Tensor.

4.2 Procesare digitală de semnal

Aceste tehnici complexe de procesare au fost utilizate în aplicatie pentru identificarea emotiei din voce. Aceasta procesare nu va identifica cuvintele rostite de candidat, ci va încerca în functie de anvelopa acustica, să determine starea persoanei care este interviuata.

În mod natural, vocea este transmisa urechii umane printr-o unda acustica care se deplaseaza prin intermediul aerului, cu viteza sunetului. Din momentul în care este înregistrata de către un microfon, sunetul este transmis printr-un fir ca un semnal electric care se deplaseaza cu viteza luminii. Pentru a face acest eveniment posibil, semnalul acustic generat de corzile vocale umane trebuie mai întâi transformat într-un semnal electric și apoi convertit într-o forma acustica, pentru a putea fi înțeles de către oameni. Semnalul electric convertit este în mod conventional într-o forma analogica. Adica este reprezentat ca o tensiune care variaza continuu într-un interval dat (0 și 1). Datorita degradarii semnalului electric în cazul stocarii, a deplasarii acestuia pe distante lungi sau a procesarii de către un calculator, se prefera transformarea lui într-o forma digitala.

Indiferent de domeniul utilizat (timpului sau frecventelor), urmatorii termeni prezentati mai jos vor ajuta în înțelegerea procesului de identificare a emotiilor:

- Rata de esantionare (Sample rate): reprezinta numarul de date (sample-uri) care sunt înregistrate într-o secunda. Cu cât avem rata de esantionare mai mare, cu atât calitatea semnalului va fi mai ridicata. Spre exemplu, rata de esantionare folosita în general pentru scrierea CD-urilor cu muzica este de 44.1 KHz (kilo Herti). Asta înseamna ca o data la o secunda 44100 de date sunt înregistrate, pe care le putem studia.
- Fereastra (Window): semnalul poate fi segmentat într-un numarul egal de sample-uri
- Numarul de linii spectrale: simbolizeaza numarul de frecvente identificate în urma transformarii din domeniul timpului în cel al frecventelor

Datele înregistrate de către microfon se vor afla în domeniul timpului. În aceeași sfera, principalul neajuns este reprezentat de insuficienta de operatii folositoare pe care le putem utiliza în identificarea emotiilor vocii. Pentru a satisface cerintele necesare analizei sentimentelor din voce, vom efectua trecerea din domeniul timpului în cel al frecventelor utilizând Transformata Fourier [10].

4.2.1 Transformata Fourier

Fiind folosită în multiple domenii precum procesarea imaginilor, studiul semnalelor (incluzând cele acustice), transformata Fourier este un procedeu matematic care ne ajută la trecerea unui semnal din domeniul timpului în cel al frecvențelor. Avantajul analizei în acest domeniu este dat gama diversificată de informații precum și de operații pe care le putem folosi.

O puternică unealtă matematică, transformata Fourier (Jean-Baptiste Joseph Fourier) asumă faptul că un semnal poate fi descompus ca o sumă de sinusuri/cosinusuri.




Figura 6: Semnal ca fiind o sumă de sinusuri

<https://community.sw.siemens.com/s/article/what-is-the-fourier-transform>

Din Figura 6 se poate observa cum un semnal definit de amplitudine și timp, poate descompus într-o sumă de sinusuri, de frecvențe diferite.




Figura 7: Domeniul frecvențelor

<https://community.sw.siemens.com/s/article/what-is-the-fourier-transform>

Datorită motivelor enunțate în pagina anterioară care justifică necesitatea transformării în domeniul frecvențelor, vom explica acest fenomen cu ajutorul Figurii 7.

Putem observa ca semnalul reprezentat de culoarea mov este descompus din alte trei semnale. In urma aplicarii transformatei Fourier peste acest semnal, liniile spectrale reprezinta principalele frecvente recunoscute.

Din punct de vedere matematic, transformata Fourier este :

$$S_x(f) = \int_{-\infty}^{+\infty} x(t)e^{-j2\pi ft} dt \quad (1)$$

unde $S_x(f)$ reprezintă frecvența măsurată în Hz iar $x(t)$ este semnalul în domeniul timpului. Rezultatul acestei operații este un număr complex (spre exemplu $a+bj$ este un număr complex întrucât a reprezintă partea reală iar b partea imaginară).

4.2.2 Transformata Fourier pe termen scurt

Adesea, transformata Fourier este evitata in a fi folosita in forma ei simpla in practica. Motivul este dat de variatiile prea bruste si multiple pe care semnalul le poate avea in domeniul timpului. Interpretarea unui semnal dintr-un singur segment devine problematica si costisitoare din punct de vedere al performantelor. O solutie fezabila este segmentarea semnalului in intervale mici, care mai apoi vor fi interpretate in mod individual. Aceasta tehnica poarta numele de transformata Fourier pe termen scurt (short time Fourier Transform, STFT).

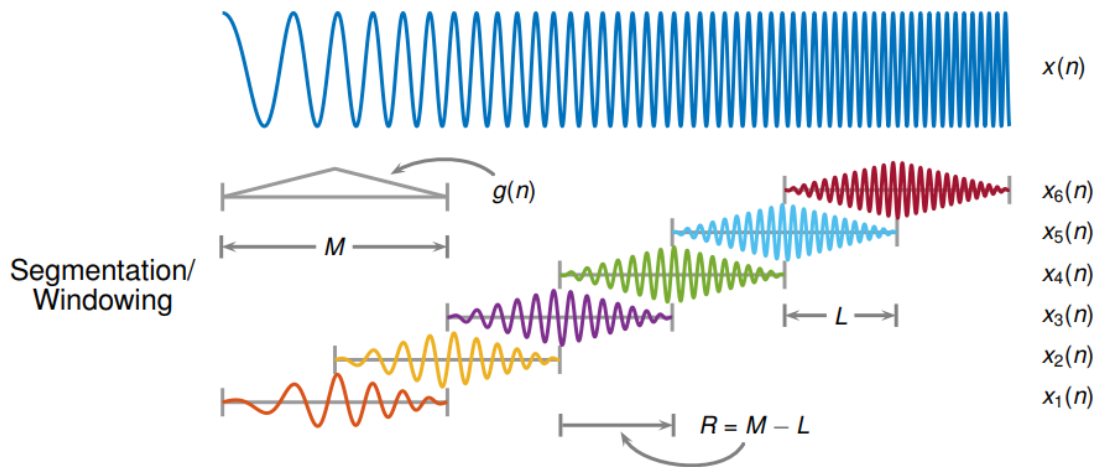


Figura 8: Domeniul frecvențelor
<https://nl.mathworks.com/help/signal/ref/stft.html>

Dupa cum se poate observa in Figura 8, se aplica succesiv transformata Fourier pe segmente mici de date. Lungimea unui segment este aleasa in mod arbitrar, dar se recomanda sa se foloseasca puteri ale lui 2, pentru a spori eficienta algoritmului. Acest proces este documentat ca fiind etapa de "windowing". O proprietate speciala pe care o are acest procedeu este dat de intercalarea segmentelor. Prin utilizarea

ferestrei in mod intercalat, vom avea posibilitatea de a obtine valorile frecventelor intr-un mod mai determinist.




Figura 9: Spectograma unui fișier audio folosit în antrenare

Rezultatul obtinut in urma aplicarii transformatei Fourier pe termen scurt poate fi interpret sub forma unui grafic care poarta denumirea de spectograma sau "waterfall" (cascada). In exemplul din Figura 9, intr-un spatiu cartezian XOY, axa OX reprezinta timpul iar cealalta axa arata puterea lui. In functie de intensitatea culorilor, putem determina degradarea precum si anvelopa acustica a semnalului sonor.

4.3 Procesarea imaginilor

Bibliography

- [1] K. Vimaladeví C. Vinola. A Survey on Human Emotion Recognition Approaches, Databases and Applications. Accessed: 16.05.2022 (cit. on p. 3).
- [2] Giannoukos I. Anagnostopoulos C N Iliou T. Features and classifiers for emotion recognition from speech: a survey from 2000 to 2011. Artificial Intelligence Review, 2015, 43(2):155-177. (in NETHERLANDS). Accessed: 16.05.2022 (cit. on p. 3).
- [3] Google Speech to Text. <https://cloud.google.com/speech-to-text/>. Accessed: 17.05.2022 (cit. on p. 3).
- [4] Big Five personality traits. https://en.wikipedia.org/wiki/Big_Five_personality_traits/. Accessed: 17.05.2022 (cit. on p. 3).
- [5] OpenCv. <https://opencv.org/>. Accessed: 17.05.2022 (cit. on p. 5).
- [6] C. Darwin and P. Prodger. The expression of the emotions in man and animals. Oxford University Press, USA, 1998. Accessed: 17.05.2022 (cit. on p. 5).
- [7] Noldus FaceReader. <https://www.noldus.com/facereader/>. Accessed: 17.05.2022 (cit. on p. 6).
- [8] IMotions Fea - Facial Expression Analysis. <https://imotions.com/biosensor/fea-facial-expression-analysis/>. Accessed: 17.05.2022 (cit. on p. 6).
- [9] NVIDIA CUDA. <https://developer.nvidia.com/cuda-zone/>. Accessed: 19.05.2022 (cit. on p. 14).
- [10] Transformata Fourier. https://ro.wikipedia.org/wiki/Transformata_Fourier/. Accessed: 19.05.2022 (cit. on p. 15).

	Titlu trimitere	ID lucrare Turnitin	Trimis	Similaritate	
Vizualizare confirmare digitală	Utilizarea tehnicilor de procesare de semnal în domeniul învățării automate	1258270301	18/06/2020 22:44	2% 	Trmite lucrare   --

Figura 10: Licență similaritate